1 牛顿迭代法

1.1 方程求根

首先,选择一个接近函数 f(x) 零点的 x_0 ,计算相应的 $f(x_0)$ 和切线斜率 $f'(x_0)$ (这里 f' 表示函数 f 的导数)。然后我们计算穿过点 $(x_0, f(x_0))$ 并且斜率为 $f'(x_0)$ 的直线和 x 轴的交点的 x 坐标,也就是求如下方程的解:

 $f(x_0) = (x_0 - x) \cdot f'(x_0)$ 我们将新求得的点的 x 坐标命名为 x_1 ,通常 x_1 会比 x_0 更接近方程 f(x) = 0 的解。因此我们现在可以利用 x_1 开始下一轮迭代。迭代公式可化简为如下所示:

 $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$ 已经证明,如果 f' 是连续的,并且待求的零点 x 是孤立的,那么在零点 x 周围存在一个区域,只要初始值 x_0 位于这个邻近区域内,那么牛顿法必定收敛。并且,如果 f'(x) 不为 0,那么牛顿法将具有平方收敛的性能. 粗略的说,这意味着每迭代一次,牛顿法结果的有效数字将增加一倍。

1.2 海森矩阵

在数学中,海森矩阵(Hessian matrix 或 Hessian)是一个自变量为向量的实值函数的二阶偏导数组成的方块矩阵,此函数如下:

 $f(x_1, x_2, \ldots, x_n)$, 如果 f 所有的二阶导数都存在, 那么 f 的海森矩阵即:

$$H(f)_{ij}(x) = D_i D_j f(x)$$
 其中 $x = (x_1, x_2, \dots, x_n)$,即

$$H(f) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \\ \vdots & \vdots & \ddots & \vdots \\ \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

当函数 $f: \mathbb{R}^n \to \mathbb{R}$ 二阶连续可导时,Hessian 矩阵 H 在临界点 x_0 上是一个 $n \times n$ 阶的对称矩阵。

当 H 是正定矩阵时, 临界点 x_0 是一个局部的极小值。

当 H 是负定矩阵时,临界点 x_0 是一个局部的极大值。

H=0,需要更高阶的导数来帮助判断。

在其余情况下,临界点 x_0 不是局部极值。

1.3 函数最优化

给定二阶导数连续的函数 $f: \mathbb{R}^2 \to \mathbb{R}$, 在 $(x + \Delta x)$ 点按 Taylar 展开, 得:

$$f(x + \Delta x) \approx Q(x) = f(x) + \nabla f(x)^T \Delta x + \frac{1}{2} \Delta x^T H(x) \Delta x$$

其中 $\Delta x = x_{n+1} - x_n$, $\nabla f(x)$ 是 f(x) 的梯度, H(x) 是 Hessian 矩阵。

$$\diamondsuit \nabla Q(x) = \nabla f(x) + H(x)\Delta x = 0$$

得到
$$H(x)(x_{n+1}-x_n)=-\nabla f(x)$$

所以,n 元函数最优化的牛顿迭代公式为: $x_{n+1} = x_n - H(x)^{-1}\nabla f(x)$